

MACHINE LEARNING IN HEALTHCARE

Rapport de Projet

Prédiction du Risque de Mortalité

Lea FELIZARDO & Stella DUPONT

E4 – Semestre 2 2025/2026

Dataset : GOSSIS-1-eICU

0. Introduction et choix du jeu de données

0.1. Description du dataset

Pour ce projet, nous avons sélectionné le dataset GOSSIS-1-eICU, un sous-ensemble de la base Global Open Source Severity of Illness Score (v1.0.0) disponible sur PhysioNet. Ce jeu de données tabulaire massif regroupe des informations sur 131 051 patients uniques provenant de 204 hôpitaux différents.

La base est particulièrement riche avec 216 variables initiales. Elle comprend des données démographiques (âge, IMC), des signes vitaux (fréquence cardiaque, pressions artérielles, température) et des résultats de laboratoire (lactates, créatinine, pH). Elle inclut également des scores cliniques de référence, notamment les diagnostics APACHE III, qui servent de standard international pour évaluer la sévérité des pathologies en soins intensifs.

0.2. Question clinique

L'enjeu de notre étude est de répondre à la question suivante :

“Au terme des 24 premières heures en soins intensifs, peut-on prédire avec précision le risque de mortalité hospitalière finale ?”

Pour répondre à cette problématique, nous avons identifié la variable `hospital_death` comme cible principale. Il s'agit d'une variable binaire où la valeur 0 représente la survie et la valeur 1 le décès au cours de l'hospitalisation. Cette approche nous permet d'évaluer la trajectoire du patient après sa première journée de prise en charge critique.

0.3. Objectif

Ce projet vise à construire un outil d'aide à la décision clinique capable de prédire le risque de mortalité hospitalière d'un patient en soins intensifs, à partir des seules données biologiques et des signes vitaux recueillis lors de ses 24 premières heures d'admission. Pour cela, nous comparons plusieurs algorithmes de Machine Learning afin d'identifier le modèle offrant le meilleur compromis entre performance prédictive et interprétabilité médicale.

0.4. Outils de travail

- **Jupyter Notebook** : développement code
- **GitHub** : partage du code de manière professionnelle et structurée

1. Analyse exploratoire des données

Dans un premier temps, nous chargeons le fichier “propre” du dataset GOSSIS-1-eICU (*gossis-1-eicu-only-model-ready.csv*), directement disponible sur Physionet. Nous pourrions ensuite comparer nos résultats à une analyse faite sur le dataset brut, que nous nettoierons nous même.

Ce fichier est supposé être déjà nettoyé, mais nous vérifions tout de même la présence de valeurs manquantes, de doublons, de valeurs aberrantes et d’incohérences de types.

1.1. Aperçu du jeu de données

131 051

patients

71

variables

204

hôpitaux

1.1.1. Types de variables

numériques : 64 colonnes

catégorielles : 7 colonnes

1.1.2. Description des variables

Le dataset contient 71 variables réparties en plusieurs groupes fonctionnels. Les colonnes *d1_..._avg* représentent la moyenne sur le premier jour, les colonnes *d1_..._diff* représentent l’amplitude (max – min) sur le premier jour, capturant l’instabilité du patient.

Voici un tableau explicatif de toutes les variables :

#	Variable	Type	Catégorie	Description
1	patientunitstayid	ID	Identifiant	Identifiant unique du séjour en USI
2	encounter_id	ID	Identifiant	Identifiant unique de la rencontre patient
3	partition	Catégorielle	Métadonnée	Partition train/test du dataset (2 modalités)
4	age	Numérique	Démographie	Âge du patient en années
5	d1_diasbp_avg	Numérique	Signe vital J1	Pression artérielle diastolique : moyenne J1
6	d1_hearttrate_avg	Numérique	Signe vital J1	Fréquence cardiaque : moyenne J1
7	d1_mbp_avg	Numérique	Signe vital J1	Pression artérielle moyenne : moyenne J1
8	d1_resprate_avg	Numérique	Signe vital J1	Fréquence respiratoire : moyenne J1
9	d1_spo2_avg	Numérique	Signe vital J1	Saturation en oxygène (SpO2) : moyenne J1
10	d1_sysbp_avg	Numérique	Signe vital J1	Pression artérielle systolique : moyenne J1

#	Variable	Type	Catégorie	Description
11	d1_temp_avg	Numérique	Signe vital J1	Température corporelle : moyenne J1
12	d1_albumin_avg	Numérique	Biologie J1	Albumine sérique : moyenne J1
13	d1_bilirubin_avg	Numérique	Biologie J1	Bilirubine : moyenne J1
14	d1_bun_avg	Numérique	Biologie J1	Urée sanguine (BUN) : moyenne J1
15	d1_creatinine_avg	Numérique	Biologie J1	Créatinine : moyenne J1
16	d1_glucose_avg	Numérique	Biologie J1	Glycémie : moyenne J1
17	d1_hco3_avg	Numérique	Biologie J1	Bicarbonates : moyenne J1
18	d1_hemaglobin_avg	Numérique	Biologie J1	Hémoglobine : moyenne J1
19	d1_hematocrit_avg	Numérique	Biologie J1	Hématocrite : moyenne J1
20	d1_inr_avg	Numérique	Biologie J1	INR (coagulation) : moyenne J1
21	d1_lactate_avg	Numérique	Biologie J1	Lactatémie : moyenne J1
22	d1_platelets_avg	Numérique	Biologie J1	Plaquettes : moyenne J1
23	d1_potassium_avg	Numérique	Biologie J1	Kaliémie (potassium) : moyenne J1
24	d1_sodium_avg	Numérique	Biologie J1	Natrémie (sodium) : moyenne J1
25	d1_calcium_avg	Numérique	Biologie J1	Calcémie : moyenne J1
26	d1_wbc_avg	Numérique	Biologie J1	Globules blancs (WBC) : moyenne J1
27	d1_arterial_pco2_avg	Numérique	Biologie J1	pCO2 artériel : moyenne J1
28	d1_arterial_ph_avg	Numérique	Biologie J1	pH artériel : moyenne J1
29	d1_arterial_po2_avg	Numérique	Biologie J1	pO2 artériel : moyenne J1
30	d1_pao2fio2ratio_avg	Numérique	Biologie J1	Ratio PaO2/FiO2 (insuffisance respiratoire) : moyenne J1
31	d1_diasbp_diff	Numérique	Amplitude J1	Pression diastolique : amplitude J1 (max – min)
32	d1_hearttrate_diff	Numérique	Amplitude J1	Fréquence cardiaque : amplitude J1
33	d1_mbp_diff	Numérique	Amplitude J1	Pression artérielle moyenne : amplitude J1
34	d1_resprate_diff	Numérique	Amplitude J1	Fréquence respiratoire : amplitude J1
35	d1_spo2_diff	Numérique	Amplitude J1	SpO2 : amplitude J1
36	d1_sysbp_diff	Numérique	Amplitude J1	Pression systolique : amplitude J1
37	d1_temp_diff	Numérique	Amplitude J1	Température : amplitude J1
38	d1_albumin_diff	Numérique	Amplitude J1	Albumine : amplitude J1
39	d1_bilirubin_diff	Numérique	Amplitude J1	Bilirubine : amplitude J1
40	d1_bun_diff	Numérique	Amplitude J1	Urée (BUN) : amplitude J1
41	d1_creatinine_diff	Numérique	Amplitude J1	Créatinine : amplitude J1
42	d1_glucose_diff	Numérique	Amplitude J1	Glycémie : amplitude J1
43	d1_hco3_diff	Numérique	Amplitude J1	Bicarbonates : amplitude J1
44	d1_hemaglobin_diff	Numérique	Amplitude J1	Hémoglobine : amplitude J1

#	Variable	Type	Catégorie	Description
45	d1_hematocrit_diff	Numérique	Amplitude J1	Hématocrite : amplitude J1
46	d1_inr_diff	Numérique	Amplitude J1	INR : amplitude J1
47	d1_lactate_diff	Numérique	Amplitude J1	Lactatémie : amplitude J1
48	d1_platelets_diff	Numérique	Amplitude J1	Plaquettes : amplitude J1
49	d1_potassium_diff	Numérique	Amplitude J1	Potassium : amplitude J1
50	d1_sodium_diff	Numérique	Amplitude J1	Sodium : amplitude J1
51	d1_calcium_diff	Numérique	Amplitude J1	Calcium : amplitude J1
52	d1_wbc_diff	Numérique	Amplitude J1	Globules blancs : amplitude J1
53	d1_arterial_pco2_diff	Numérique	Amplitude J1	pCO2 artériel : amplitude J1
54	d1_arterial_ph_diff	Numérique	Amplitude J1	pH artériel : amplitude J1
55	d1_arterial_po2_diff	Numérique	Amplitude J1	pO2 artériel : amplitude J1
56	d1_pao2fio2ratio_diff	Numérique	Amplitude J1	Ratio PaO2/FiO2 : amplitude J1
57	dx_class	Catégorielle	Diagnostic	Classe diagnostique principale (113 modalités)
58	dx_sub	Catégorielle	Diagnostic	Sous-diagnostic précis (398 modalités)
59	vent	Binaire	Traitement	Patient sous ventilation mécanique (0/1)
60	arf_apache	Binaire	Score	Insuffisance rénale aiguë selon score APACHE (0/1)
61	dcs_group	Catégorielle	Contexte	Groupe de sortie de soins intensifs (4 modalités)
62	icu_admit_source	Catégorielle	Contexte	Source d'admission en USI (5 modalités) : 0,18% NaN
63	aids	Binaire	Comorbidité	SIDA (0/1)
64	cirrhosis	Binaire	Comorbidité	Cirrhose hépatique (0/1)
65	diabetes_mellitus	Binaire	Comorbidité	Diabète (0/1)
66	lymphoma	Binaire	Comorbidité	Lymphome (0/1)
67	solid_tumor_with_metastasis	Binaire	Comorbidité	Tumeur solide métastatique (0/1)
68	group	Catégorielle	Contexte	Groupe clinique du patient (12 modalités)
69	elective_surgery	Binaire	Contexte	Chirurgie programmée / élective (0/1)
70	hospital_death	Binaire ☹	Cible	Décès à l'hôpital : variable cible principale (0/1)
71	icu_death	Binaire ☹	Cible	Décès en USI : variable cible secondaire (0/1)

1.1.3. Qualité des données

Avant de commencer à visualiser et à interpréter nos données, nous allons vérifier la propreté du dataset. Nous avons résumé dans un tableau les résultats obtenus en exécutant une vérification des valeurs manquantes, des doublons et du bon type de variable dans chaque colonne.

Critère	Résultat
Valeurs manquantes	Présente dans 1 colonne (icu_admit_source) 0,18% de NA (négligeable)
Doublons	0 doublon détecté
Variables catégorielles à convertir	partition, dcs_group, icu_admit_source, group, dx_class, dx_sub
Valeurs aberrantes	62 variables concernées. On conserve les valeurs car elles sont représentatives de pathologies aiguës. Leur suppression biaiserait la prédiction de la mortalité.

1.2. Nettoyage des données

1.2.1. Suppression NA & identifiants

Nous avons supprimé les lignes (les patients) qui présentent des valeurs manquantes puisque cela représente une partie négligeable de toutes nos données (241 patients sur 131 051).

Nous avons retiré les deux variables “identifiants”, car elles ne sont pas utiles pour l’analyse. Nous avons également converti les colonnes object en categorical, défini la variable cible, que nous avons nommé TARGET, et séparé les variables explicatives de la variable cible.

1.2.2. Encodage variable catégorielle

Notre code détecte dx_class et dx_sub, comme du texte, alors qu’il s’agit de variables catégorielles qui correspondent au type de pathologies (cardiovascular, respiratory, trauma...).

Analyse des colonnes 'Object' :

Colonne	Uniques	Suggestion
encounter_id	131051	Texte/ID
partition	2	Categorical
dx_class	113	Texte/ID
dx_sub	398	Texte/ID
dcs_group	4	Categorical
icu_admit_source	5	Categorical
group	12	Categorical

Ces deux variables décrivent la pathologie d’admission avec deux niveaux de précision :

- **dx_class** : Famille de diagnostic associée à un préfixe numérique (ex: 1207Cardiovascular).
- **dx_sub** : Sous-catégorie ultra-spécifique (ex: 011207CardiovascularCardiovascular)

Nous allons donc utiliser uniquement la variable dx_class pour notre analyse et supprimer dx_sub. La variable dx_class a plusieurs catégories qui pointent en fait vers la même pathologie (113 groupes différents) mais avec un code numérique en préfixe. Afin d’améliorer la robustesse du modèle et de faciliter l’interprétation clinique, nous avons procédé à un nettoyage pour supprimer ces codes.

Nous avons à présent 12 catégories différentes :

#	Catégorie
1	Cardiovascular
2	Gastrointestinal
3	Genitourinary
4	Gynecological
5	Hematological
6	Metabolic
7	Musculoskeletal/Skin
8	Neurological
9	Other medical disorders
10	Respiratory
11	Sepsis
12	Trauma

1.2.3. Dataset après nettoyage

130 810

patients

67

variables

1 variable cible

hospital_death


1.3. Etude de la variable cible

Pour mieux appréhender notre analyse, nous allons étudier notre TARGET (**hospital_death**). Nous utilisons **hospital_death** comme variable cible et non **icu_death**, puisque nous souhaitons savoir s'il est possible de prédire la mort du patient ou non, pas simplement s'il est décédé en soins intensifs ou non.

De plus, garder **icu_death** pour prédire **hospital_death** créerait ce qu'on appelle un "Data Leakage" car si un patient meurt en soins intensifs (**icu_death** = 1), il est certain qu'il meurt à l'hôpital (**hospital_death** = 1).

Résultats :

Survivants (0) : 118 993 (91,0%)	Décès (1) : 11 817 (9,0%)
----------------------------------	---------------------------




Sur 130 810 patients, 118 993 sont des survivants (91,0%) et 11 817 sont décédés (9,0%), soit un ratio d'environ 1 décès pour 10 survivants.

Ce déséquilibre impose des choix méthodologiques importants : l'accuracy sera écartée comme métrique principale au profit de l'AUC-ROC et du recall sur la classe positive, la validation croisée sera stratifiée pour préserver le ratio dans chaque fold, et le seuil de décision de 0,5 sera remis en question (un seuil abaissé permettant de mieux détecter les patients à risque de décès, ce qui est prioritaire dans un contexte de triage).

1.4. Analyse de Corrélation

Nous allons à présent identifier, parmi les 68 variables, celles qui possèdent le plus fort pouvoir prédictif vis-à-vis de la mortalité hospitalière.


Les résultats présentés ci-dessous mettent en évidence le Top 15 des variables présentant la plus forte corrélation avec le décès hospitalier (classées par valeur absolue).



L'analyse met en évidence la prédominance des marqueurs de l'hypoxie tissulaire et de la détresse métabolique. Le lactate moyen (**d1_lactate_avg**) est le prédicteur le plus puissant ($r = 0.381$), suivi de la nécessité d'une ventilation mécanique et des gaz du sang (pH).

Fait notable : la présence de plusieurs variables d'amplitude (**_diff**) dans le Top 15 souligne que l'instabilité des constantes est un signal d'alerte aussi crucial que les valeurs absolues.

Après avoir identifié les variables les plus corrélées à notre cible (**hospital_death**), il faut étudier les relations entre ces 15 variables explicatives. Cette étape permet de détecter la multi-colinéarité, c'est-à-dire des variables qui apportent la même information, ce qui pourrait biaiser certains modèles de classification.



L'analyse de la matrice de corrélation montre plusieurs points clés :

- La grande majorité des coefficients de corrélation entre les variables indépendantes se situe entre -0.4 et $+0.4$. Cela indique que chaque biomarqueur apporte une information spécifique et complémentaire, justifiant leur maintien dans le modèle.
- On observe une corrélation forte entre `d1_spo2_avg` et `d1_spo2_diff` (-0.94). C'est une relation logique : une saturation moyenne faible est souvent associée à une grande instabilité (amplitude élevée) de l'oxygène au cours de la première journée.
- Le lactate moyen (`d1_lactate_avg`) et son amplitude (`d1_lactate_diff`) présentent une corrélation de 0.56 , confirmant que la gravité de l'état métabolique est liée à sa fluctuation.
- Si le taux de CO_2 varie brusquement (`d1_arterial_pco2_diff`) , le pH (`d1_arterial_ph_diff`) va mathématiquement varier dans la foulée. Cette corrélation élevée montre que chez les patients instables, les variations du pH sont directement dictées par des problèmes de ventilation ou de régulation du gaz carbonique.


Malgré des liens physiologiques prévisibles, l'absence de colinéarité généralisée garantit une diversité d'information suffisante pour la phase de modélisation. Nous disposons désormais d'un "socle" de variables prioritaires dont nous allons maintenant étudier la distribution concrète.

1.5. Profilage clinique


L'objectif de cette étude visuelle par Boxplots est de valider concrètement le potentiel prédictif de nos variables. En comparant les distributions des survivants (0) et des décédés (1), nous cherchons à identifier si nos données sont "séparables", c'est-à-dire si les comportements biologiques des deux groupes sont suffisamment distincts pour qu'un algorithme puisse les différencier.

Ce que nous apprennent les Boxplots :


- Parmi les variables les plus discriminantes, on a :
 - Le lactate moyen (d1_lactate_avg) : les patients décédés présentent une médiane environ 3 fois supérieure aux survivants, avec de nombreuses valeurs extrêmes traduisant des états d'hypoxie tissulaire sévère.
 - Le pH artériel (d1_arterial_ph_avg) et son instabilité (d1_arterial_ph_diff) montrent également une séparation claire : les décédés présentent un pH plus bas et plus variable, signe d'une acidose persistante et fluctuante.
 - L'albumine (d1_albumin_avg) se distingue dans le sens inverse, une hypoalbuminémie est associée au décès, reflet d'un état inflammatoire et nutritionnel défavorable.
 - L'urée (d1_bun_avg) est également plus élevée chez les décédés, évoquant une atteinte rénale plus fréquente.



- En revanche, certaines variables présentent un chevauchement important des distributions : La SpO2 moyenne (d1_spo2_avg), l'instabilité thermique (d1_temp_diff) et la variation du ratio PaO2/FiO2. Ces variables apportent une information limitée de manière isolée, mais peuvent contribuer à la performance globale du modèle dans un cadre multivarié.



- Concernant la variable vent (ventilation mécanique), la représentation en boxplot est inadaptée pour une variable binaire. Une analyse en proportions serait plus appropriée pour évaluer son pouvoir discriminant.



En conclusion, cette exploration visuelle valide la séparabilité de nos données pour une majorité des variables du Top 15, et justifie le recours à des algorithmes de classification capables d'exploiter ces différences de distribution, notamment pour les cas où la séparation est partielle mais réelle.

2. Méthodologie et Protocole Expérimental

2.1. Nature du problème

Nous traitons un problème de classification binaire supervisée. Il s'agit de prédire si un patient décède à l'hôpital (1) ou survit (0). Face au fort déséquilibre des classes (91% / 9%), l'accuracy est écartée au profit de l'AUC-ROC, qui mesure la capacité de discrimination globale du modèle, et de la sensibilité (recall), qui quantifie la proportion de décès correctement identifiés.

2.2. Choix des variables

Nous avons choisi de d'abord tester la régression logistique avec les 67 variables, avant de la comparer à la régression logistique à partir du Top 15 des variables les plus discriminantes, pour quantifier le coût réel de la réduction de variables. Puisque le modèle Top 15 capture l'essentiel du signal prédictif, tous les modèles suivants seront entraînés exclusivement sur ce Top 15, pour trois raisons concrètes :

- Ces 15 biomarqueurs (Lactate, pH, Urée...) sont des examens de routine disponibles en 15 à 30 minutes dans tout service de réanimation.
- Restreindre le nombre de variables rend le modèle physiologiquement interprétable par un médecin.
- Supprimer les variables secondaires réduit le risque de surapprentissage et améliore la robustesse des prédictions.

2.3. Pipeline de prétraitement

Toute la chaîne de transformation est encapsulée dans un Pipeline scikit-learn pour garantir l'étanchéité absolue entre train et test : le StandardScaler centre et réduit les variables numériques, et le OneHotEncoder transforme les variables catégorielles en vecteurs numériques. Ces transformations sont exclusivement ajustées sur le jeu d'entraînement, puis appliquées au jeu de test, pour éviter le risque de data leakage.

2.4. Stratégie de validation

Les performances sont estimées par validation croisée stratifiée à 5 folds, qui découpe le jeu d'entraînement en 5 sous-ensembles tout en préservant le ratio de classes. Cette approche permet de s'assurer que les résultats ne dépendent pas d'un découpage particulier des données et de détecter un éventuel surapprentissage avant l'évaluation finale sur le jeu de test.

2.5. Gestion du déséquilibre des classes

Deux stratégies sont testées pour pallier le déséquilibre :

- Configuration 1 : le paramètre `class_weight='balanced'` pénalise davantage les erreurs sur la classe minoritaire lors de l'entraînement.
- Configuration 2 : un sous-échantillonnage aléatoire réduit le dataset à 30 000 patients équilibrés (15k survivants / 15k décédés), forçant les modèles à accorder un poids égal aux deux classes au prix d'une légère perte d'AUC.

3. Modélisation et Entraînement

3.1. Configuration 1 : Jeu de données complet (130 810 patients)

Dans cette première configuration, nous entraînons nos modèles sur l'intégralité du dataset sans modifier la distribution naturelle des classes, afin d'évaluer les performances brutes de chaque algorithme dans des conditions réalistes.


3.1.1. Régression Logistique (Baseline)

Nous commençons notre phase de modélisation par la Régression Logistique. Ce modèle est choisi pour sa transparence et sa simplicité : il permet de vérifier si un lien linéaire direct existe entre nos variables et la mortalité. Ce score constitue notre "base" à battre pour justifier l'usage d'algorithmes plus complexes.

Pour chaque modèle testé dans ce rapport, nous adopterons une double approche comparative :

- L'approche "Full" (67 variables) : Nous entraînons d'abord le modèle sur l'intégralité des données disponibles. L'objectif est ici la performance pure et la précision statistique maximale, en laissant l'algorithme exploiter les signaux les plus faibles et les comorbidités.
- L'approche "Parcimonieuse" (Top 15 variables) : Nous testons ensuite une version simplifiée, limitée aux 15 variables les plus discriminantes identifiées lors de l'EDA.


Résultats approche "Full"



Résultats Régression Logistique (Approche Full) :

Métrique	Jeu de Test
AUC-ROC :	0.8841
Sensibilité (Recall) :	0.7761

Résultats approche “Top 15”




Résultats Régression Logistique (Approche Top 15) :

Métrique	Jeu de Test
AUC-ROC :	0.8382
Sensibilité (Recall) :	0.7148

Interprétation : Les résultats montrent que le passage de 67 à 15 variables entraîne une baisse de l'AUC-ROC de presque 0.05 (soit environ 5%). Bien que significative, cette différence montre que le 'Top 15' capture déjà près de 84% du signal prédictif total, ce qui n'est pas mal du tout.

Forest Plot des Odds Ratios




Le Forest Plot des Odds Ratios permet de visualiser l'impact réel de chaque variable. On voit que, le lactate élevé, la ventilation mécanique et l'acidose (pH bas) apparaissent comme les principaux facteurs de risque, tandis qu'une albumine normale et une bonne saturation en oxygène jouent un rôle protecteur. Cela permet au médecin de valider que les

prédictions de l'IA reposent sur une logique médicale cohérente (ex: danger du lactate) et non sur des corrélations arbitraires.

3.1.2. Arbre de Décision

Nous entraînons ensuite un arbre de décision, avec une profondeur de 3 niveaux pour qu'il soit lisible. L'arbre est utile car il est facilement interprétable par un médecin. L'arbre de décision permet de visualiser la logique prédictive du modèle sous forme de règles binaires successives. Chaque "nœud" représente une question clinique, et chaque "feuille" finale représente une probabilité de décès.



Comment lire cet arbre ?

Prenons un cas concret : un patient avec un lactate moyen de 3.0 mmol/L et sous ventilation mécanique.

- Niveau 1 : Le lactate moyen est-il ≤ 2.447 ? Non ($3.0 > 2.447$) → on part à droite, dans la zone bleue (Décès probable).
- Niveau 2 : Le lactate est-il ≤ 3.801 ? Oui ($3.0 \leq 3.801$) → on part à gauche. On arrive sur un nœud qui pose la question de la ventilation mécanique.
- Niveau 3 : Le patient est-il ventilé ? Oui ($\text{vent} = 1$, donc $\text{vent} \leq 0.5$ est Faux) → on part à droite. On arrive sur une feuille avec $\text{gini} = 0.484$ et $\text{value} = [2448, 3508]$, soit une majorité de décès → classe prédite : Décès.

Évaluation de l'Arbre de Décision (Visualisation) :



Modèle :	Arbre de Décision (Profondeur = 3)
AUC-ROC :	0.7989
Sensibilité (Recall) :	0.6686

Note : Ce modèle est volontairement limité à une profondeur de 3 niveaux pour garantir son interprétabilité clinique immédiate.

Avec une AUC de 0.799 et un Recall de 0.669, l'arbre de décision offre des performances honorables compte tenu de sa profondeur volontairement limitée à 3 niveaux, mais une sensibilité de 67% n'est pas acceptable en milieu médical.

3.1.3. Random Forest

Nous entraînons ensuite un Random Forest sur le Top 15. Ce modèle est réputé pour sa robustesse et sa capacité à capturer des interactions non-linéaires entre variables, ce qui le rend particulièrement adapté à des données biologiques complexes.





Résultats Random Forest (Approche Top 15) :

Métrique	Validation Croisée (moy ± std)	Jeu de Test
AUC-ROC :	0.855 ± 0.005	0.8502
Sensibilité (Recall) :	0.188 ± 0.003	0.1803

Interprétation : Les résultats du Random Forest sont surprenants. L'AUC-ROC est solide à 0.850, mais la sensibilité chute à seulement 0.18. Concrètement, le modèle ne détecte que 18% des décès, il classe presque tous les patients comme survivants, ce qui est statistiquement correct sur un dataset à 91% de survie, mais cliniquement inacceptable. Ce résultat illustre parfaitement le problème du déséquilibre des classes et justifie directement le passage à la Configuration 2, où nous allons forcer les modèles à mieux apprendre la classe minoritaire via le rééchantillonnage.

3.1.4. XGBoost



Résultats XGBoost (Approche Top 15 - Échantillon Complet) :

AUC-ROC : 0.8547

Sensibilité (Recall) : 0.7385

Note : XGBoost utilise le paramètre 'scale_pos_weight' pour compenser le déséquilibre des classes sur l'échantillon total.

Le XGBoost est le dernier modèle testé en Configuration 1 et est le meilleur de cette phase, avec une AUC de 0.855 et un Recall de 0.738. Contrairement au Random Forest, il gère naturellement le déséquilibre des classes grâce au paramètre `scale_pos_weight`, qui pénalise davantage les erreurs sur la classe minoritaire sans nécessiter de rééchantillonnage.

Avec les mêmes variables et le même jeu de données, XGBoost détecte près de 74% des décès là où le Random Forest n'en détectait que 18%. C'est ce modèle que nous retenons comme champion de la Configuration 1, et sa performance servira de référence pour évaluer l'apport réel du rééchantillonnage en Configuration 2.

Conclusion

Les résultats de la Configuration 1 mettent en évidence une tendance claire : l'AUC ne change pas énormément entre les différents modèles, mais la sensibilité évolue de façon déterminante.

Le tableau ci-dessous résume les performances de chaque modèle :

Modèle	AUC-ROC	Sensibilité
Régression Logistique	0,8382	0,7149
Arbre de décision	0,7989	0,6686
Random Forest	0,8502	0,1803
XGBoost	0,8547	0,7385


Notre vainqueur, dans la Configuration 1 est le modèle XGBoost, puisqu'il a la sensibilité la plus élevée, qui est la métrique la plus importante dans le milieu médical. Il détecte 73,9% des patients à haut risque, ce qui est honorable, mais pas encore suffisant. Pour tenter d'améliorer la sensibilité de notre prédiction, nous allons passer à la Configuration 2.

3.2. Configuration 2 : Jeu sous-échantillonné

Le Random Forest en Config 1 avait un recall de 0.18, ce qui est cliniquement inacceptable rater 82% des décès n'est pas une option. On crée donc un jeu équilibré (50/50) pour forcer les modèles à mieux apprendre la classe minoritaire.

3.2.1. Régression Logistique Ré-échantillonnée

Nous refaisons une régression logistique sur le jeu équilibré (9454 décès/9454 survivants) et nous l'évaluons sur le jeu de test original complet pour que les résultats restent comparables à la Configuration 1.





Les résultats sont quasiment identiques à la Configuration 1 : AUC de 0.838 et la sensibilité est de 0.716, contre 0.838 et 0.7148 précédemment.

Ce résultat montre que pour la régression logistique, le rééchantillonnage n'apporte aucun gain mesurable, le paramètre `class_weight='balanced'` utilisé en Configuration 1 gère déjà le déséquilibre des classes.

3.2.2. Random Forest Ré-échantillonné

De la même façon, nous ré-entraînons un Random Forest sur le jeu équilibré. Voici les résultats obtenus :



Résultats Random Forest après rééquilibrage manuel (Undersampling) :


AUC-ROC : 0.8526

Sensibilité (Recall) : 0.7651

La sensibilité du Random Forest bondit de 0.18 à 0.765, tout en maintenant une AUC solide à 0.853. Cela montre que Random Forest n'était pas un mauvais modèle en Configuration 1, il était simplement aveugle à la classe minoritaire faute d'exemples suffisants lors de l'entraînement.

Ce résultat place le Random Forest ré-échantillonné au niveau de XGBoost en termes de Recall (0.765 vs 0.738), avec une AUC légèrement inférieure (0.853 vs 0.855).

3.3. Synthèse Comparative Finale



Conclusion

Le tableau ci-dessous résume les performances de chaque modèle :

Données	Modèle	AUC-ROC	Sensibilité
Jeu de données complet	Régression Logistique	0,8382	0,7149
	Arbre de décision	0,7989	0,6686
	Random Forest	0,8502	0,1803
	XGBoost	0,8547	0,7385
Jeu de données ré-échantillonné	Régression Logistique	0,8378	0,7160
	Random Forest	0,8526	0,7651

Plusieurs enseignements ressortent de cette comparaison :

- Premièrement, le rééchantillonnage est décisif pour le Random Forest : son Recall passe de 0.18 à 0.765, ce qui en fait soudainement un modèle cliniquement viable. En revanche, il n'apporte rien à la régression logistique, qui gère déjà bien le déséquilibre grâce à `class_weight='balanced'`.
- Deuxièmement, XGBoost s'impose comme le meilleur modèle global sans nécessiter de rééchantillonnage : il combine la meilleure AUC (0.855) avec un Recall élevé (0.738).

4. Conclusion & Perspectives Cliniques

4.1. Bilan des performances

Cette démarche de modélisation nous montre qu'il est possible de prédire la mortalité hospitalière avec une précision plutôt satisfaisante à partir de seulement 15 variables significatives. L'enjeu était de pallier au déséquilibre des classes. Le modèle XGBoost s'impose comme le modèle le plus performant avec une AUC de 0.855 et une sensibilité de 0.738, sans nécessiter de modification du dataset. Il détecte correctement près de 3 décès sur 4, ce qui représente un niveau de performance cliniquement exploitable.

Le Random Forest ré-échantillonné atteint des performances très proches (AUC 0.853, Recall 0.765), mais au pris de perte de données.

4.2. Interprétation médicale

Les variables les plus discriminantes identifiées par nos modèles sont cohérentes avec la littérature clinique en réanimation. Le lactate moyen est le prédicteur le plus puissant : un taux élevé traduit une hypoxie tissulaire sévère, signe que les organes ne reçoivent plus suffisamment d'oxygène. Le pH artériel bas reflète une acidose métabolique persistante, souvent associée à un état de choc. L'urée élevée évoque une atteinte rénale, fréquente chez les patients en défaillance multi-organes. La nécessité d'une ventilation mécanique traduit quant à elle une détresse respiratoire grave.

4.3. Application concrète

Ce modèle pourrait être intégré comme outil d'aide à la décision dans les services de réanimation, en générant automatiquement un score de risque dès la fin de la première journée d'hospitalisation.

	d1_lactate_avg	vent	d1_arterial_ph_avg	d1_spo2_diff	d1_spo2_avg	d1_inr_avg	d1_lactate_diff	d1_albumin_avg	d1_bun_avg	d1_temp_diff
count	618.000000	618.000000	618.000000	618.000000	618.000000	618.000000	618.000000	618.000000	618.000000	618.000000
mean	1.680583	0.338188	7.378620	9.103159	94.727862	1.510426	0.302238	2.988530	26.504007	0.983566
std	0.591793	0.473476	0.055040	10.120215	5.124967	0.698106	0.589731	0.524806	21.317295	0.684891
min	0.112503	0.000000	7.054000	0.000000	50.000000	0.880000	-1.200735	0.900000	4.000000	-0.064980
25%	1.299802	0.000000	7.356311	4.000000	93.625000	1.200000	0.000000	2.700000	14.000000	0.500000
50%	1.614300	0.000000	7.383244	7.000000	95.500000	1.401150	0.170690	3.026526	20.000000	0.800000
75%	2.000000	1.000000	7.410000	10.000000	97.000000	1.620585	0.456410	3.319945	30.000000	1.300000
max	4.355000	1.000000	7.595000	100.000000	100.000000	14.050000	5.300000	4.900000	189.000000	4.400000

d1_heartate_diff	d1_arterial_ph_diff	d1_arterial_pco2_diff	d1_pao2fio2ratio_diff	d1_hco3_avg
618.000000	618.000000	618.000000	618.000000	618.000000
32.598362	0.041817	4.323089	17.807915	24.725516
19.040692	0.058320	7.587285	63.849445	4.823006
0.000000	-0.053609	-0.986774	-46.283623	8.000000
20.000000	0.003179	1.241754	-6.322077	22.000000
29.000000	0.037241	3.000000	0.000000	24.105699
42.000000	0.053885	4.585949	18.138336	27.000000
147.000000	0.810000	100.000000	1046.285714	51.000000

L'analyse des 618 faux négatifs (XG Boost) révèle un profil biologique atypique : ces patients présentent une albumine quasi normale, une SpO2 satisfaisante et des constantes hémodynamiques peu perturbées au premier jour. Ce sont des patients dont la dégradation est probablement tardive ou liée à des causes non captées par nos 15 biomarqueurs

(complication infectieuse secondaire, défaillance d'organe progressive, ou décision médicale de limitation des soins).

Il est essentiel de rappeler que ce modèle ne remplace pas le jugement clinique : il vise à prioriser la surveillance des patients les plus à risque et à alerter le praticien, pas à se substituer à lui. Dans un contexte de triage où les ressources sont limitées, un outil capable de détecter 74% des décès à partir de 15 examens de routine disponibles en 30 minutes représente une aide concrète et immédiatement déployable.

4.5. Pistes d'amélioration

Plusieurs axes pourraient améliorer les performances futures. L'application de SMOTE (sur-échantillonnage synthétique) pourrait générer des exemples artificiels de décès pour enrichir l'entraînement sans perdre de données comme avec le sous-échantillonnage. La création de variables composites, comme un score combinant lactate et pH, pourrait également renforcer le pouvoir prédictif. Enfin, des modèles de survie comme Cox ou Kaplan-Meier permettraient de passer d'une prédiction binaire à une estimation temporelle du risque, pour une vision dynamique de l'évolution du patient au-delà des premières 24 heures.